

# Mon Projet Data Science

## Projet Fil Rouge Data Science - Sujet Libre

Étudiant(e) 1 : Hugo RAGUIN    Étudiant(e) 2 : Amine TALEB    Étudiant(e) 3 : Elliot FIORESE

2026-05-18

### Table of contents

|       |                                                                         |    |
|-------|-------------------------------------------------------------------------|----|
| 1     | Exécution avec Docker .....                                             | 2  |
| 1.1   | Parcours recommandé .....                                               | 3  |
| 1.2   | Exécution détaillée étape par étape .....                               | 3  |
| 2     | Introduction et Contexte Métier .....                                   | 4  |
| 2.1   | Contexte du Projet .....                                                | 4  |
| 2.2   | Objectif Analytique .....                                               | 5  |
| 2.3   | Synthèse .....                                                          | 5  |
| 2.4   | Positionnement par Rapport au Cahier des Charges .....                  | 6  |
| 3     | Acquisition et Préparation des Données (Data Wrangling) .....           | 6  |
| 3.1   | Audit de Qualité .....                                                  | 6  |
| 3.2   | Algorithme de Nettoyage .....                                           | 7  |
| 3.3   | Travaux Pratiques de Wrangling .....                                    | 8  |
| 4     | Analyse Exploratoire des Données (EDA) .....                            | 8  |
| 4.1   | Statistiques Descriptives .....                                         | 8  |
| 4.2   | Ingénierie de Variables (Feature Engineering) .....                     | 8  |
| 4.3   | Travaux Pratiques d'Exploration Visuelle (EDA) .....                    | 9  |
| 5     | Visualisation Multidimensionnelle (Insights) .....                      | 9  |
| 5.1   | Profils et Distributions Caractéristiques .....                         | 9  |
| 5.2   | Corrélations Globales .....                                             | 10 |
| 6     | Modélisation et Apprentissage .....                                     | 11 |
| 6.1   | Schéma Global du Pipeline de Données .....                              | 11 |
| 6.2   | Modélisation Tabulaire (Machine Learning) .....                         | 11 |
| 6.2.a | Travaux Pratiques de Modélisation Tabulaire .....                       | 12 |
| 6.3   | Modélisation Vision / Deep Learning (Analyse d'Images ou Signaux) ..... | 12 |
| 6.3.a | Travaux Pratiques de Vision par Ordinateur (CNN) .....                  | 14 |
| 7     | Évaluation Métrique et Validation .....                                 | 14 |
| 7.1   | Stratégie de Validation .....                                           | 14 |
| 7.2   | Validation Croisée Stratifiée .....                                     | 14 |
| 7.3   | Résultats et Interprétation .....                                       | 15 |
| 8     | Data Storytelling et Communication .....                                | 15 |

|                                                 |    |
|-------------------------------------------------|----|
| 8.1 Tableau de Bord Interactif .....            | 15 |
| 8.2 Matrice d'Action Pédagogique .....          | 15 |
| 8.3 Recommandations Stratégiques / Métier ..... | 16 |
| 8.4 Limites et Perspectives .....               | 16 |
| 8.5 Supports de Restitution .....               | 17 |
| Bibliographie .....                             | 17 |
| Bibliography .....                              | 17 |

## 1 Exécution avec Docker

Si vous ne souhaitez rien installer localement, tout le projet peut être exécuté avec Docker Compose depuis la racine du dépôt. Le dépôt est monté dans le conteneur via `./:/workspace`, donc les fichiers générés restent directement disponibles dans votre copie locale.

Dans cette configuration, le seul prérequis local est Docker avec le plugin Compose: Python, Quarto, Typst et Go-Task sont déjà fournis dans l'image du projet.

Le parcours recommandé est maintenant simplement:

```
docker compose up --build
```

Ce lancement fait automatiquement les actions suivantes:

- Le service datascience exécute `tools/docker_bootstrap.py`.
- Chaque étape est affichée dans la console avec son rôle, le fichier principal de logique et l'emplacement des résultats.
- Le fetch du dataset original est rappelé avec le fichier de logique, le lien source UCI et l'emplacement local du brut.
- Le journal complet est écrit à la racine dans le fichier `log.md`.
- Une fois la génération terminée, le service presentation sert les livrables sur `http://localhost:8000`.

Le dataset public d'origine est celui de l'UCI:

- `https://archive.ics.uci.edu/static/public/697/predict+students+dropout+and+academic+success.zip`
- logique de fetch: `src/student_risk_dataset.py`
- copie brute locale: `data/raw/student_risk/student_dropout_source.csv`
- trace de la source active: `data/raw/student_risk/student_dropout_source.json`

Les résultats principaux se trouvent ici:

- `log.md`
- `report/assets/tp3_student_dashboard.html`
- `report/presentation.html`
- `report/rapport.html`
- `report/installation.html`

## 1.1 Parcours recommandé

Si vous préférez piloter les étapes une par une, utilisez les commandes suivantes.

1. Construire l'image Docker:

```
docker compose build
```

2. Rejouer rapidement le pipeline tabulaire et vérifier les artefacts principaux:

```
docker compose run --rm datascience task smoke
```

3. Lancer la vérification complète, y compris la brique CNN:

```
docker compose run --rm datascience task verify
```

4. Régénérer le rapport Quarto et mettre à jour le README:

```
docker compose run --rm datascience task render
```

5. Servir les livrables HTML sur <http://localhost:8000>:

```
docker compose up presentation
```

6. Prévisualiser le rapport Quarto en direct sur <http://localhost:4200>:

```
docker compose --profile preview up preview
```

## 1.2 Exécution détaillée étape par étape

Si vous préférez lancer chaque phase séparément, utilisez les commandes suivantes:

1. Wrangling des données:

```
docker compose run --rm datascience python src/tp1_student_wrangling.py
```

2. Analyse exploratoire:

```
docker compose run --rm datascience python src/tp2_student_eda.py
```

3. Modélisation tabulaire:

```
docker compose run --rm datascience python src/tp3_student_modelisation.py
```

4. Génération des figures du rapport:

```
docker compose run --rm datascience python src/generate_report_figures.py
```

5. Exécution de la démonstration CNN:

```
docker compose run --rm datascience python src/tp4_synthetic_cnn.py
```

6. Vérification finale des artefacts produits:

```
docker compose run --rm datascience python tools/verify_project.py --include-cnn
```

7. Mise à jour du README uniquement au format Markdown:

```
docker compose run --rm datascience task gfm
```

## 2 Introduction et Contexte Métier



Figure 1: CI Compilation Pipeline

Le sujet principal retenu pour ce projet est la **prédiction du risque d’abandon scolaire ou d’échec académique**. La problématique métier consiste à identifier le plus tôt possible les étudiants à risque afin de déclencher des actions ciblées: tutorat, suivi pédagogique, accompagnement social ou adaptation du rythme d’apprentissage.

L’enjeu n’est pas uniquement de prédire une cible binaire. Il s’agit aussi de construire une chaîne analytique défendable, lisible par une équipe pédagogique et exploitable pour l’aide à la décision. Le livrable final doit donc articuler nettoyage de données, exploration explicative, modélisation tabulaire et ouverture vers une brique vision liée à des copies scannées ou à de l’écriture manuscrite.

### 2.1 Contexte du Projet

Le domaine d’étude est celui de l’**analytics éducatif**. Un établissement d’enseignement ou un service de réussite étudiante dispose souvent de données fragmentées: notes continues, absences, retard dans les remises, temps de connexion à une plateforme pédagogique, participation en classe, statut boursier, parcours antérieur ou indicateurs socio-économiques. Isolément, ces variables sont peu actionnables; combinées, elles permettent de détecter des signaux faibles de décrochage.

Ce sujet est pertinent scientifiquement et stratégiquement. Il répond à un besoin réel de prévention, mobilise des variables tabulaires hétérogènes, soulève des questions de biais et d’équité, et se prête naturellement à une extension multimodale via l’analyse de copies numérisées, de formulaires pédagogiques ou d’écritures manuscrites.

## 2.2 Objectif Analytique

La cible principale sera une variable de type `dropout_risk`, `failure_risk` ou `success_status`, selon le jeu de données final retenu. Le problème est donc formulé comme une **classification supervisée**, éventuellement complétée par une analyse de probabilité de risque pour prioriser les interventions pédagogiques.

Les livrables analytiques sont les suivants:

- un jeu de données nettoyé et un jeu de données prêt pour la modélisation;
- des indicateurs descriptifs et des visualisations métier sur l'assiduité, les résultats académiques et l'engagement étudiant;
- un modèle de classification de référence comparé à une baseline naïve pour repérer les profils à risque;
- une brique CNN documentée, pensée pour être raccordée à des copies scannées, de l'écriture manuscrite ou des documents pédagogiques numérisés.

Note méthodologique: le pipeline tabulaire repose sur le jeu UCI *Predict Students' Dropout and Academic Success*, harmonisé vers le schéma analytique du projet. Un générateur synthétique local est conservé comme solution de repli afin d'assurer l'exécution du pipeline si la source publique devient indisponible.

## 2.3 Synthèse

Le travail mené couvre les deux jalons du projet autour d'un même cas d'usage: la détection précoce du risque de décrochage étudiant. L'ensemble de la démarche articule préparation de données, analyse exploratoire, modélisation supervisée et ouverture vers une composante vision par ordinateur.

Les principaux résultats obtenus peuvent être résumés ainsi:

- le pipeline aboutit à une base étudiante cohérente, nettoyée et enrichie par des variables dérivées interprétables;
- l'analyse exploratoire met en évidence des contrastes nets selon les programmes, le statut boursier et la dynamique semestrielle;
- la régression logistique constitue le meilleur compromis pour une logique d'alerte précoce, avec un rappel de **0,806** et un ROC-AUC de **0,909** sur le jeu de test;
- la branche CNN, encore démonstrative, confirme la faisabilité technique d'une extension future vers des documents pédagogiques numérisés.

## 2.4 Positionnement par Rapport au Cahier des Charges

| Dimension attendue      | Traitement retenu dans ce rapport                                                              | Supports mobilisés                                                          |
|-------------------------|------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------|
| Préparation des données | Audit des manques, imputation, création de variables dérivées et encodage pour la modélisation | src/<br>student_risk_dataset.py, src/<br>tp1_student_wrangling.py           |
| Analyse exploratoire    | Statistiques descriptives, profils par programme, distributions et corrélations                | src/tp2_student_eda.py,<br>tableaux de data/processed                       |
| Visualisation           | Figures métier générées à partir du schéma harmonisé du projet                                 | src/<br>generate_report_figures.py,<br>figures du dossier report/<br>assets |
| Modélisation            | Comparaison entre baseline, régression logistique et Random Forest                             | src/<br>tp3_student_modelisation.py                                         |
| Évaluation              | Lecture conjointe de l'accuracy, du rappel, du F1-score et du ROC-AUC                          | data/processed/<br>tp3_model_metrics.csv                                    |
| Restitution             | Interprétation métier, matrice d'action pédagogique et discussion des limites                  | sections d'analyse et de storytelling du présent rapport                    |

Cette structuration permet de maintenir une continuité entre les attendus pédagogiques du cours et la progression réelle de l'étude, sans dissocier artificiellement les phases exploratoires, prédictives et de communication.

---

## 3 Acquisition et Préparation des Données (Data Wrangling)

Le succès de tout projet de Data Science repose sur la qualité de la préparation des données [1]. Cette section documente l'audit de qualité et les étapes de nettoyage appliquées à vos jeux de données bruts.

### 3.1 Audit de Qualité

Le jeu brut harmonisé retenu par défaut contient **4 424 étudiants** et **16 variables**, avec une cible dropout\_risk égale à **32,1 %** de la population (**1 421 étudiants à risque** sur 4 424). Les identifiants du projet sont reconstruits lors de l'harmonisation afin de garantir l'unicité locale et la traçabilité du pipeline.

Sur les variables retenues dans ce schéma harmonisé, aucune valeur manquante structurante n'est observée. Le contrôle de complétude confirme que les colonnes tabulaires conservées sont renseignées sur l'ensemble de la cohorte.

Le wrangling reste néanmoins indispensable. Il stabilise les types, normalise les booléens, prépare les variables dérivées et conserve une logique d'imputation compatible avec le dataset synthétique de secours ou avec d'autres sources qui seraient moins propres que l'archive UCI.

**Aucune valeur manquante  
observée sur le schéma tabulaire retenu.**

Le pipeline conserve toutefois la logique de contrôle et  
d'imputation pour rester compatible avec les autres sources.

Figure 2: Top 10 des valeurs manquantes observées dans le jeu étudiant brut.

### 3.2 Algorithme de Nettoyage

Le pipeline de nettoyage est implémenté dans `src/student_risk_dataset.py` et `src/tp1_student_wrangling.py`. La logique retenue est la suivante:

1. harmonisation d'un dataset public existant quand il est demandé, avec repli automatique vers un dataset brut réaliste généré localement;
2. normalisation des booléens et conversion robuste des colonnes numériques;
3. création de drapeaux de non-réponse pour `attendance_rate`, `prior_average` et `continuous_assessment`;
4. imputation médiane sur les variables quantitatives, `False` sur les booléens et `Unknown` sur les catégories;
5. création de variables dérivées interprétables: `engagement_score`, `grade_trend_gap` et `academic_pressure_index`;
6. encodage one-hot des variables catégorielles pour obtenir une table directement exploitable par Scikit-Learn.

Le pipeline ne supprime aucune ligne: la cohorte complète de **4 424 étudiants** est conservée. La sortie wranglée contient **22 colonnes** et la table `model_ready` **37 colonnes**.

### 3.3 Travaux Pratiques de Wrangling

Le script de wrangling génère deux sorties versionnées:

- `data/processed/tp1_student_risk_wrangled.csv` pour l'analyse métier;
- `data/processed/tp1_student_risk_model_ready.csv` pour la modélisation supervisée.

Cette séparation est particulièrement importante dans un contexte éducatif, car les enseignants et responsables de formation doivent pouvoir relire les données et comprendre les transformations appliquées.

---

## 4 Analyse Exploratoire des Données (EDA)

Dans cette section, nous analysons les relations statistiques fondamentales qui régissent votre domaine d'étude au sein du jeu de données.

### 4.1 Statistiques Descriptives

Le profil moyen observé est celui d'un étudiant de **23,27 ans**, travaillant **17,01 heures par semaine**, se connectant **14,77 fois par semaine** au LMS, avec un **taux d'assiduité moyen de 78,74 %** et un **délai moyen de remise de 1,42 jour**. La note antérieure moyenne est de **13,26/20** et l'évaluation continue moyenne de **10,75/20**.

| Programme (exemples contrastés) | Assiduité moyenne | Évaluation continue moyenne | Taux de risque |
|---------------------------------|-------------------|-----------------------------|----------------|
| Nursing                         | 86.24 %           | 12.52                       | 15.4 %         |
| Social Service                  | 83.93 %           | 11.35                       | 18.3 %         |
| Informatics Engineering         | 66.57 %           | 9.38                        | 54.1 %         |
| Biofuel Production Technologies | 66.63 %           | 10.19                       | 66.7 %         |

Le contraste métier est net: Nursing et Social Service restent relativement protégés, alors que Informatics Engineering et surtout Biofuel Production Technologies concentrent les niveaux de risque les plus élevés. Cette hétérogénéité plaide pour une lecture segmentée par programme, et non pour une politique uniforme de prévention.

### 4.2 Ingénierie de Variables (Feature Engineering)

L'ingénierie de variables transforme ici les traces brutes en signaux pédagogiques exploitables. Trois variables ont été construites explicitement:

- `engagement_score`, qui combine assiduité, temps de travail, activité LMS et retards de remise;
- `grade_trend_gap`, qui mesure l'écart entre l'évaluation continue et la moyenne antérieure;
- `academic_pressure_index`, qui agrège stress, retards et dégradation d'assiduité.



Ces variables dérivées ont deux avantages. Elles améliorent la capacité prédictive du modèle, mais surtout elles restent compréhensibles par les équipes éducatives. Une alerte fondée sur la baisse des notes, la chute d'engagement et la hausse de pression académique est plus défendable qu'un score opaque.

### 4.3 Travaux Pratiques d'Exploration Visuelle (EDA)

L'exploration visuelle est calculée dans `src/tp2_student_eda.py` et mise en forme dans `src/generate_report_figures.py`. Les visuels générés dans `report/assets` documentent le cas d'étude étudiant retenu dans ce rapport.

---

## 5 Visualisation Multidimensionnelle (Insights)

Nous présentons ici les visualisations cibles du projet et la manière dont elles doivent être interprétées pour une cellule de réussite étudiante.

L'EDA montre que le risque académique n'est pas aléatoire. Il se concentre sur quelques dimensions stables: performance récente, assiduité, engagement numérique et contexte socio-éducatif.

### 5.1 Profils et Distributions Caractéristiques




Figure 3: Taux de risque selon le statut boursier et évolution par semestre.

Trois insights ressortent immédiatement:

- le statut boursier joue un rôle protecteur marqué dans ce dataset: **38,71 %** des non-boursiers sont classés à risque contre **12,19 %** des boursiers;
- le risque n'est pas homogène selon les programmes: Biofuel Production Technologies atteint **66,7 %** contre **15,4 %** pour Nursing;
- la structure du jeu UCI met surtout en évidence les deux premiers semestres observés, avec **42,78 %** de risque au semestre 1 contre **31,67 %** au semestre 2.

Ces contrastes justifient le recours à un score de risque multicritère, plutôt qu'à une lecture limitée à la moyenne générale.

## 5.2 Corrélations Globales




Figure 4: Matrice de corrélation entre engagement, notes et assiduité.

La matrice de corrélation met en évidence plusieurs relations structurantes. La plus forte corrélation observée est celle entre `prior_average` et `continuous_assessment` (**0,756**), ce qui est cohérent avec la continuité du niveau académique. À l'inverse, `assignment_delay_days` est négativement corrélé à `continuous_assessment` (**-0,386**) et à `prior_average` (**-0,360**), ce qui renforce l'idée que les retards de remise sont un bon proxy de fragilité. La matrice de corrélation met en évidence plusieurs relations structurantes. La plus forte corrélation observée est logiquement celle entre `study_hours_per_week` et `engagement_score` (**0,920**), puisque ce score intègre explicitement le volume de travail. Parmi les relations plus interprétables, `attendance_rate` est fortement corrélée à `continuous_assessment` (**0,771**) et négativement à `stress_index` (**-0,776**). À l'inverse, `assignment_delay_days` reste négativement corrélé à `attendance_rate` (**-0,387**) et à `engagement_score` (**-0,424**), ce qui renforce l'idée que les retards de remise capturent une fragilité organisationnelle.

L'objectif n'est donc pas seulement descriptif. Cette lecture permet aussi d'identifier les variables redondantes, les dépendances fortes et les agrégations utiles pour la modélisation.

---

## 6 Modélisation et Apprentissage

### 6.1 Schéma Global du Pipeline de Données

Le pipeline complet intègre à la fois la branche analytique tabulaire (Machine Learning) et la branche d'analyse visuelle ou de signaux complexes (Deep Learning CNN) :

```
graph TD
    A[Notes absences LMS contexte social] -->|Jointure et anonymisation| B[Table etudiante brute]
    B -->|Nettoyage et harmonisation| C[Table nettoye]
    C -->|Feature engineering pedagogique| D[Table model-ready]
    D -->|Split temporel ou stratifie| E[Modele tabulaire]
    E -->|Score de risque + importances| F[Tableau de bord pedagogique]
    G[Copies scannees / ecriture manuscrite] -->|CNN TensorFlow| H[Variables visuelles complementaires]
    H --> F
    F --> I[Rapport Quarto et restitution]

    style C fill:#e0f2fe,stroke:#0284c7,stroke-width:2px
    style I fill:#f0fdf4,stroke:#16a34a,stroke-width:2px
    style E fill:#fef3c7,stroke:#d97706,stroke-width:2px
    style H fill:#fef3c7,stroke:#d97706,stroke-width:2px
```

### 6.2 Modélisation Tabulaire (Machine Learning)

La branche tabulaire est implémentée dans `src/tp3_student_modelisation.py`. Trois modèles sont comparés:

- une baseline majoritaire, pour mesurer le niveau minimal de référence;
- une régression logistique, plus adaptée à une lecture opérationnelle centrée sur le rappel;
- une forêt aléatoire, utilisée ici pour sa robustesse et pour le classement des variables explicatives.

Le protocole retenu combine deux niveaux d'évaluation complémentaires. Un **split stratifié en 80/20** est conservé pour estimer la performance finale sur un jeu de test indépendant. En parallèle, une **validation croisée stratifiée à 5 plis** est réalisée sur l'échantillon d'entraînement afin de comparer les modèles sur plusieurs sous-échantillons et de réduire la dépendance à un découpage unique. Sur un dataset réel multi-semestres, ce protocole devrait ensuite évoluer vers un découpage chronologique ou par cohorte.




Figure 5: Top 10 des variables explicatives du risque étudiant.

Les variables les plus influentes dans la forêt aléatoire sont `attendance_rate` (**0,167**), `academic_pressure_index` (**0,145**), `engagement_score` (**0,112**), `stress_index` (**0,099**) et `study_hours_per_week` (**0,081**). Le modèle capture donc un mélange cohérent d'**assiduité**, de **pression académique** et d'**engagement pédagogique**.

### 6.2.a Travaux Pratiques de Modélisation Tabulaire

La modélisation produit trois sorties clés dans `data/processed`:

- `tp3_model_metrics.csv` pour les scores comparatifs;
- `tp3_cross_validation_metrics.csv` pour la synthèse de validation croisée stratifiée;
- `tp3_feature_importance.csv` pour le classement des variables;
- `tp3_predictions_sample.csv` pour un échantillon de prédictions individuelles.

### 6.3 Modélisation Vision / Deep Learning (Analyse d'Images ou Signaux)

La branche Deep Learning est implémentée dans `src/tp4_synthetic_cnn.py`. À ce stade, elle sert de **preuve de faisabilité technique** pour l'intégration d'une chaîne vision dans le même environnement reproductible que la branche tabulaire.

Le script génère aujourd'hui **120 images RGB synthétiques** de taille  $64 \times 64$  réparties en deux classes simples. Cette approche n'est pas la finalité métier du projet; elle prépare plutôt l'étape suivante, dans laquelle le CNN pourra être appliqué à des copies scannées, à de l'écriture manuscrite, à des formulaires pédagogiques ou à des traces visuelles issues d'un environnement d'apprentissage.

L'architecture CNN reste volontairement compacte:

- bloc Conv2D(16) + MaxPooling2D;
- bloc Conv2D(32) + MaxPooling2D;
- Flatten, Dense(32), Dropout(0.2), puis sortie sigmoïde.




Figure 6: Exemples d'images synthétiques générées pour la brique CNN.




Figure 7: Courbes d'apprentissage du CNN sur 5 époques.

Le modèle est entraîné sur **96 images** et validé sur **24 images**. Il atteint une **accuracy de validation de 1,00** et une `validation_loss` finale très faible lors des exécutions Docker du

projet. Ce score est cohérent avec la simplicité du problème visuel utilisé comme démonstrateur. Il valide la chaîne TensorFlow, mais ne constitue pas encore un résultat métier sur des documents éducatifs réels.

### 6.3.a Travaux Pratiques de Vision par Ordinateur (CNN)

Les sorties de cette branche sont exportées dans `data/processed/tp4_cnn_history.csv`, `data/processed/tp4_cnn_metrics.csv` et `data/processed/tp4_cnn_predictions.csv`, ainsi que dans deux figures du dossier `report/assets`.

---

## 7 Évaluation Métrique et Validation

### 7.1 Stratégie de Validation

La validation de la branche tabulaire repose ici sur un protocole en deux temps. D’abord, les modèles sont comparés par **validation croisée stratifiée à 5 plis** sur l’échantillon d’entraînement, ce qui permet d’observer la stabilité des métriques sur plusieurs découpages. Ensuite, le modèle retenu est réévalué sur un **jeu de test hold-out stratifié 80/20**, conservé à l’écart de la phase de sélection.

Ce choix est cohérent avec le jeu UCI harmonisé par défaut, qui agrège des informations d’inscription et de performance sur les deux premiers semestres au sein d’un même établissement. Dans un cadre réel multi-cohortes, il faudrait néanmoins renforcer encore le protocole en privilégiant un découpage chronologique, par cohorte ou par groupe pédagogique afin d’éviter toute fuite d’information entre périodes d’observation.

Pour la branche CNN, le démonstrateur actuel repose sur un hold-out 80/20. Dans un contexte éducatif réel, cette brique devra être évaluée soit par validation croisée, soit sur un jeu de documents réellement séparé par session, matière ou promotion.

### 7.2 Validation Croisée Stratifiée

| Modèle                | Accuracy CV | Recall CV | F1 CV | ROC-AUC CV |
|-----------------------|-------------|-----------|-------|------------|
| Baseline majoritaire  | 0.679       | 0.000     | 0.000 | 0.500      |
| Régression logistique | 0.849       | 0.806     | 0.774 | 0.903      |
| Random Forest         | 0.855       | 0.703     | 0.757 | 0.900      |

La validation croisée confirme un arbitrage plus serré que sur la version synthétique du projet. La régression logistique reste la mieux alignée avec une logique d’alerte précoce, car elle maintient un **rappel moyen de 0,806** tout en conservant un **ROC-AUC de 0,903**. La forêt aléatoire est compétitive en accuracy moyenne (**0,855** contre **0,849**), mais son rappel moyen descend à **0,703**, ce qui reste moins favorable si l’objectif prioritaire est de détecter le maximum d’étudiants fragiles.

### 7.3 Résultats et Interprétation

Les métriques prioritaires sont la **précision**, le **rappel**, le **F1-score** et le **ROC-AUC**, car le coût d'une erreur n'est pas symétrique. Un faux négatif signifie qu'un étudiant à risque n'est pas détecté; un faux positif signifie qu'un étudiant reçoit un suivi inutile.

| Modèle                | Accuracy | Rappel | F1-score | ROC-AUC |
|-----------------------|----------|--------|----------|---------|
| Baseline majoritaire  | 0.679    | 0.000  | 0.000    | N/A     |
| Régression logistique | 0.851    | 0.806  | 0.776    | 0.909   |
| Random Forest         | 0.856    | 0.715  | 0.762    | 0.909   |

Le résultat clé est que **la régression logistique reste le meilleur choix opérationnel** pour un système d'alerte précoce. Elle offre le meilleur rappel (**0,806**) tout en conservant un **ROC-AUC de 0,909**, ce qui signifie qu'elle détecte davantage d'étudiants à risque. La forêt aléatoire obtient une accuracy légèrement supérieure (**0,856**) ainsi qu'une précision plus élevée (**0,815**), mais son rappel (**0,715**) laisse échapper davantage d'étudiants fragiles.

Ce compromis est cohérent avec le métier: un système d'alerte précoce supporte souvent un rappel élevé, quitte à assumer davantage de faux positifs, parce que le coût d'une intervention pédagogique légère reste inférieur au coût d'un abandon non détecté.

---

## 8 Data Storytelling et Communication

### 8.1 Tableau de Bord Interactif

Le livrable principal de restitution est un tableau de bord interactif autonome. Il rassemble dans une même interface les métriques du jeu de test, les résultats de validation croisée, les variables explicatives dominantes, les profils de risque par programme et une liste prioritaire d'étudiants à suivre.

Le dashboard principal est disponible dans le fichier suivant: [Dashboard interactif](#).

Un mini-deck complémentaire sert de guide de lecture du dashboard et reste disponible dans [Slides du dashboard](#).

### 8.2 Matrice d'Action Pédagogique

| Niveau de risque | Signaux dominants                                                | Action recommandée                                             | Indicateur de suivi                                                   |
|------------------|------------------------------------------------------------------|----------------------------------------------------------------|-----------------------------------------------------------------------|
| Élevé            | Assiduité en baisse, retard de remise, chute du contrôle continu | Entretien sous 7 jours, tutorat ciblé, revue du plan de charge | Retour d'assiduité, remise des travaux, évolution du contrôle continu |

| Niveau de risque | Signaux dominants                                                  | Action recommandée                                                    | Indicateur de suivi                               |
|------------------|--------------------------------------------------------------------|-----------------------------------------------------------------------|---------------------------------------------------|
| Modéré           | Engagement irrégulier, LMS stress élevé, notes encore récupérables | Coach-ing méthodologique, point hebdomadaire, soutien organisationnel | Reprise des connexions, stabilisation des retards |
| Faible           | Bon engagement et résultats stables                                | Suivi léger et prévention standard                                    | Maintien de la dynamique académique               |

### 8.3 Recommandations Stratégiques / Métier

Les résultats suggèrent plusieurs pistes opérationnelles:

- construire un score d'alerte précoce fondé sur les absences, les notes récentes, la participation et les retards de remise;
- segmenter les actions de prévention par profil étudiant afin de distinguer les difficultés académiques, sociales et organisationnelles;
- privilégier des modèles explicables et des tableaux de bord simples, pour que les équipes pédagogiques puissent justifier les interventions;
- relier l'analyse prédictive à des actions concrètes: tutorat, rendez-vous de suivi, aide méthodologique, soutien social ou adaptation de charge.

### 8.4 Limites et Perspectives

Le projet conserve plusieurs limites explicites:

- le dataset tabulaire principal est public et réel, mais il reste **mono-institutionnel** et déjà agrégé, ce qui limite la généralisation immédiate à d'autres établissements;
- le schéma harmonisé du projet simplifie certaines variables originales de la source UCI afin de conserver une chaîne cohérente avec le fallback synthétique;
- les questions d'équité, de confidentialité et de biais socio-économiques devront être traitées explicitement avant tout usage réel;
- le modèle tabulaire n'a pas encore bénéficié d'une recherche systématique d'hyperparamètres ni d'une comparaison avec des modèles de boosting;
- la branche CNN repose pour l'instant sur un jeu d'images synthétiques simple, avant intégration de documents pédagogiques réels.

Les prolongements naturels sont donc la validation externe sur d'autres établissements ou cohortes, l'ajout de variables longitudinales par semestre ou par période d'évaluation, la comparaison entre régression logistique, Random Forest et gradient boosting, la mise en place d'un découpage plus strict par cohorte et l'ajout d'une source visuelle réelle pour remplacer la démonstration synthétique du CNN.



## 8.5 Supports de Restitution

La restitution finale s'appuie sur plusieurs supports complémentaires. Le tableau de bord interactif HTML constitue le livrable principal d'exploration métier. Il est accompagné par le rapport Quarto, qui joue le rôle de document de synthèse et d'interprétation, par un mini-deck HTML de lecture du dashboard, par un schéma Mermaid du pipeline de données, par des jeux intermédiaires et finaux exportés dans `data/processed`, ainsi que par un ensemble de figures produites dans `report/assets`. Cet agencement vise à assurer à la fois la lisibilité du raisonnement, la traçabilité des transformations et la cohérence entre les résultats chiffrés et leur interprétation métier.

Ce document dynamique a été compilé en Quarto [2].

---

## Bibliographie

### Bibliography

- [1] W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*. O'Reilly Media, 2020.
- [2] Q. D. Team, “Quarto Dynamic Publishing System: Collaborative Scientific and Technical Publishing.” Accessed: May 18, 2026. [Online]. Available: <https://quarto.org/>